



特征工程一览

1. 初步特征工程

盘古平台

- 盘古页面 - 作业开发 (负责人：王军)

The screenshot shows the '盘古大数据开发平台' (Pangu Big Data Development Platform) interface. The '作业开发' (Job Development) tab is active. The '新建作业' (New Job) form includes the following fields and options:

- 作业名称 ***: A text input field for the job name. A note below states: '作业名称由小写字母和下划线 (或数字) 组成, 且必须以字母开头'.
- 作业描述 ***: A text area for the job description.
- 调度频率 ***: A dropdown menu set to '小时' (Hourly). A note below states: '备注: 最小执行频率为每小时执行1次, 执行时间可选范围为5:00-21:59'.
- 开始时间**: A time picker set to 05:00.
- 时间间隔**: A dropdown menu set to 1.
- 小时**: A dropdown menu set to 小时.
- 结束时间**: A time picker set to 21:59.
- 指定小时**: A dropdown menu set to 5.
- 指定分钟**: A dropdown menu set to 0.
- 分钟**: A dropdown menu set to 分钟.
- airFlow_new_part.current_time**: A checkbox labeled '负载正常, 可以提交并发布作业'.
- 作业有效期 ***: A dropdown menu set to 7天.
- 是否通知 ***: A toggle switch set to '是' (Yes).
- 通知类型 ***: Radio buttons for '执行失败' (Execution Failed) and '执行成功' (Execution Successful). '执行失败' is selected.
- 通知人 ***: A dropdown menu set to 李鑫辉.

At the bottom of the form are '保存' (Save) and '取消' (Cancel) buttons.

- Python客户端 (负责人：王军)

```
import pandas as pd
from pyhive import presto
import os


class Pangu:
    def __init__(self):
        """
        初始化数据下载类
        :param table_name: 表名, 例如 's157_csc_black_industry_voice_repository'
        """
        # 不合适的cursor, 只有在紧急情况下可使用
        self.cursor = presto.connect(host='172.18.2.194', port=8888, username='ai', catalog='hive', schema='tmp').cursor()

        # 合适的cursor
        self.cursor = presto.connect(host='172.18.2.233', port=8888, username='business', catalog='hive', schema='tmp', session_props={'pangu_user': 'lijiahui', 'pangu_password': 'Nevergiveup1314@'}).cursor()

    def execute(self, sql):
        """
        # 执行查询并获取数据
        self.cursor.execute(sql)
        df = pd.DataFrame(self.cursor.fetchall(), columns=[col[0] for col in self.cursor.description], dtype=str)
        return df

    def download_data(self, sql, path):
        """
        # 执行查询并获取数据
        df = self.execute(sql)
        os.makedirs(os.path.dirname(path), exist_ok=True)
        df.to_csv(path, index=False)
        print(f"数据已成功保存到 {path}")
        return df
```

- VSCode客户端 (负责人：yqw)



- BI写SQL (负责人：李焱)

Python工具


- Label Encoding/Mapping (字符串 → One-hot编码)

2. 高级特征工程

Python工具包

- Feature-wize - 特征衍生和筛选
- OptBining - 构建评分卡/评分卡交叉验证
- 模型驱动特征挖掘 - 基于LightGBM、XGBoost的特征重要性分析

自动机器学习平台



3. 模型构建

Python模型


- 树模型：LightGBM、XGBoost

- 深度学习模型

4. 模型监控

监控产品

- 指南针 - 模型效果监控
- 二郎神告警 - 实时生产库监控



可视化工具

- TensorBoard / Weights & Biases
- Grafana