



资配订单匹配问题

一、背景

由于外部政策收紧，资金规模持续缩减，出现资产大于资金的情况。通俗的来讲，就是客户的借款需求大于钱不够分了，需要给资方找到优质的客户。

类似的场景有很多，这些都属于二分图匹配问题的典型应用：

- **出行领域**：滴滴/货拉拉的司乘匹配，美团外卖的骑手订单匹配
- **电商领域**：淘宝/京东的商品推荐，拼多多的团购匹配
- **金融领域**：同业的资金资产匹配，助贷平台的借贷匹配

对于此类二分图匹配问题，核心都是在两个不同集合之间建立最优的一对一或一对多映射关系，通过优化目标函数来实现资源的最优配置。

针对资配订单匹配这一具体场景，最常见的解决方案有两个：**二分图最优化**和**推荐算法**。

二分图最优化（如匈牙利算法/KM算法）侧重于全局最优解，通过数学建模确保匹配结果在理论上达到最优；缺点就是实时性稍逊一筹。

推荐算法则更注重当前订单的个性化匹配，通过机器学习模型学习历史数据中的复杂模式，在处理大规模数据时具有更好的可扩展性和实时性；缺点则是学习全局最优的目标较难。

二、资配订单匹配问题的变量解释

常用术语：

- 资方集合： $F = \{f_1, f_2, \dots, f_m\}$ ，是当前和嘉银进行合作的资方列表
- 订单集合： $O = \{o_1, o_2, \dots, o_n\}$ ，是当前需要考虑进行分配的订单列表，可能是一天内的所有订单
- 订单金额： $A = \{a_1, a_2, \dots, a_n\}$ ，其中 a_i 表示订单 o_i 的金额
- 资方资金容量： $C = \{c_1, c_2, \dots, c_m\}$ ，其中 c_j 表示资方 f_j 的可用资金额度
- 可行性邻接矩阵： $Adj \in \{0, 1\}^{n \times m}$ ，其中 $Adj_{i,j} = 1$ 表示订单 o_i 可以分配给资方 f_j ， $Adj_{i,j} = 0$ 表示不可行，体现的业务逻辑包含像某些资方不接受特定行业/地区的订单，资方对单笔订单金额有上下限要求等。
- 通过率矩阵： $P \in [0, 1]^{n \times m}$ ，其中 $P_{i,j}$ 表示订单 o_i 分配给资方 f_j 的综合通过率，由资方通

过率和用户发标率组成。

- 匹配决策变量： $X \in \{0, 1\}^{n \times m}$ ，其中 $X_{i,j} = 1$ 表示订单 o_i 分配给资方 f_j ， $X_{i,j} = 0$ 表示不分配

优化目标：

在满足资方容量约束和可行性约束的前提下，找到最优匹配策略 X^* 。根据不同的业务目标，可以有多种优化方向：

- **资金利用率最大化**：最大化实际放款金额与资方总可用资金的比值
- **通过率最大化**：最大化订单通过数与订单总数的比值
- **盈利金额最大化**：最大化总盈利金额
- **优质资产承接率最大化**：最大化优质资产的成功匹配比例

以**资金利用率最大化**为例，目标函数为：

$$X^* = \arg \max_X \frac{\sum_{i=1}^n \sum_{j=1}^m X_{i,j} \cdot a_i \cdot P_{i,j}}{\sum_{j=1}^m c_j}$$

约束条件：

- 每个订单最多分配给一个资方： $\sum_{j=1}^m X_{i,j} \leq 1, \forall i \in \{1, \dots, n\}$
- 资方资金计划限制： $\sum_{i=1}^n X_{i,j} \cdot a_i \leq c_j, \forall j \in \{1, \dots, m\}$
- 可行性约束（挡板）： $X_{i,j} \leq Adj_{i,j}, \forall i, j$
- 决策变量约束（订单必须完整的被分配）： $X_{i,j} \in \{0, 1\}, \forall i, j$

三、方案一：基于匈牙利算法的经典方案

1. 数学建模

目标函数（以资金利用率最大化举例）：

$$\max \frac{\sum_{i=1}^n \sum_{j=1}^m X_{i,j} \cdot a_i \cdot Adj_{i,j}}{\sum_{j=1}^m c_j}$$

约束条件：

- 每个订单最多分配给一个资方： $\sum_{j=1}^m X_{i,j} \leq 1, \forall i \in \{1, \dots, n\}$

- 资方资金计划限制： $\sum_{i=1}^n X_{i,j} \cdot a_i \leq c_j, \forall j \in \{1, \dots, m\}$
- 可行性约束（挡板）： $X_{i,j} \leq Adj_{i,j}, \forall i, j$, 其中 $Adj_{i,j} = 1$ 表示订单 o_i 和资方 f_j 之间存在可行的匹配边
- 决策变量约束（订单必须完整的被分配）： $X_{i,j} \in \{0, 1\}, \forall i, j$

2. 算法的困难点：

- **边存在性预测困难**：匈牙利算法要求准确预测每条边是否存在（即 $Adj_{i,j}$ 的值），这需要精确判断订单 o_i 是否能够被资方 f_j 接受。在实际业务中，这种预测极其困难，因为涉及复杂的业务规则、风控策略和动态的市场条件。
- **无法处理权重优化**：标准匈牙利算法主要解决最大匹配问题，而资配场景更关注带权重的优化目标（如资金利用率、通过率等），需要转换为最大权重匹配问题。

多重因素导致该算法难以落地

四、方案二：基于KM算法的经典方案

1. 数学建模

目标函数（以资金利用率最大化举例）：

$$\max \frac{\sum_{i=1}^n \sum_{j=1}^m X_{i,j} \cdot a_i \cdot P_{i,j}}{\sum_{j=1}^m c_j}$$

约束条件：

- 每个订单最多分配给一个资方： $\sum_{j=1}^m X_{i,j} \leq 1, \forall i \in \{1, \dots, n\}$
- 资方资金计划限制： $\sum_{i=1}^n X_{i,j} \cdot a_i \leq c_j, \forall j \in \{1, \dots, m\}$
- 可行性约束（挡板）： $X_{i,j} \leq Adj_{i,j}, \forall i, j$
- 决策变量约束（订单必须完整的被分配）： $X_{i,j} \in \{0, 1\}, \forall i, j$

2. 算法的困难点：

- **边存在性预测困难**：虽然KM算法不需要像匈牙利算法那样预先确定边的存在性，但仍需要准确预测订单-资方配对的通过率，这在实际业务中同样具有挑战性
- **边权重估计精度要求高**：KM算法需要精准的边权重，现有的按业务规则打包的方式，人群的方差极大的（只看通过率都各式各样）。需要精准的对客户进行划分，估计出特定客群的

通过率，才能赋能KM算法求得最优解

- **批处理延迟问题**：KM算法必须积攒一批订单进行最优化，需要在用户体验（等待）和算法最优间进行权衡

3. 解法（思路）：

聚类算法：

基于订单特征进行聚类，将相似订单归为同一类别：

$$C_k = \{o_i | \arg \min_k ||\mathbf{f}(o_i) - \mu_k||^2\}$$

其中 $\mathbf{f}(o_i)$ 为订单 o_i 的特征向量， μ_k 为第 k 个聚类中心。

通过率估计：

其中 $P_{i,j}$ 通过考虑人维度的各种标签进行聚类，稳定估计通过率：

$$P_{i,j} = P(\text{通过} | o_i \in C_{cluster(i)}, f_j) = \frac{\sum_{o \in C_{cluster(i)}} \text{历史通过数}_{o,j}}{\sum_{o \in C_{cluster(i)}} \text{历史总数}_{o,j}}$$

基于聚类结果的通过率进行KM算法求解

1. **初始化顶点标号**： $l(o_i) = \max_j (a_i \cdot P_{i,j}), l(f_j) = 0$
2. **构建相等子图**： $G_l = \{(o_i, f_j) | l(o_i) + l(f_j) = a_i \cdot P_{i,j}\}$
3. **寻找增广路径**：在相等子图中寻找匹配的增广路径（具体行为就是尝试弹出已匹配的对进行重新匹配，如果能和其他新的节点建立连接，意味着找到一个增广路径，数学上可体现为矩阵运算）
4. **更新标号**： $\delta = \min_{o_i \in S, f_j \notin T} \{l(o_i) + l(f_j) - a_i \cdot P_{i,j}\}$
5. **迭代直至完美匹配**

聚类对KM算法的关键作用：

- **数据稳定性**：通过聚类获得足够相似的样本量来稳定估计通过率
- **业务合理性**：确保相似订单获得相似的匹配策略

五、方案三：基于深度学习/传统机器学习推荐模型方案

1. 数学建模

推理阶段目标函数（以通过率最大化为例）：

$$\max \sum_{i=1}^n \sum_{k=1}^m x_{i,k} \cdot \hat{P}(\text{通过} | o_i, f_k, \theta^*)$$

其中 θ^* 为训练得到的最优参数。

2. 算法的难点：

- **多目标优化困难**：推荐系统通常针对单一目标进行优化（如点击率、转化率），而资配场景需要同时考虑资金利用率、通过率、盈利金额、优质资产承接率等多个业务目标。将多目标直接作为推荐系统的优化目标会导致模型训练困难，难以收敛到全局最优解。
- **目标函数定义模糊**：推荐系统本质上是模仿学习，需要明确定义"好的匹配"标准。在资配场景中，什么是最优匹配存在主观性和多维度权衡，难以用单一的标签y来准确表达复杂的业务目标。
- **特征-标签映射关系复杂**：推荐系统的效果高度依赖于特征x和标签y之间关系的准确建模。资配场景中，订单通过与否不仅取决于订单和资方的静态特征，还受到市场环境、资方实时状态、竞争订单等动态因素影响，这种复杂的因果关系难以通过传统的特征工程完全捕获。

3. 解法（思路）：

定义特征（以通过率最大化为例）：

订单特征： $\mathbf{o}_i = [\text{金额}_i, \text{期限}_i, \text{风险}_i, \text{行业}_i, \text{地区}_i]$

资方特征： $\mathbf{f}_k = [\text{资金量}_k, \text{偏好风险}_k, \text{行业偏好}_k, \text{地区偏好}_k]$

资方订单联合特征： $\mathbf{j}_{i,k} =$

$[\text{历史通过单数}_{i,k}, \text{历史通过率}_{i,k}, \text{平均处理时间}_{i,k}, \text{拒绝原因分布}_{i,k}]$

历史交互特征： $\mathbf{h}_{i,k} = [\text{历史通过率}_{i,k}, \text{交互次数}_{i,k}]$

标签定义：

$$y_{i,k} = \begin{cases} 1, & \text{如果订单 } o_i \text{ 被资方 } f_k \text{ 通过} \\ 0, & \text{如果订单 } o_i \text{ 被资方 } f_k \text{ 拒绝} \end{cases}$$

训练样本构建：

对于每个历史订单-资方配对 (o_i, f_k) ，构建训练样本：

$$\mathcal{D} = \{(\mathbf{x}_{i,k}, y_{i,k}) | i \in \text{所有历史订单}, k \in \text{所有资方}\}$$

其中特征向量：

$$\mathbf{x}_{i,k} = [\mathbf{o}_i; \mathbf{f}_k; \mathbf{j}_{i,k}; \mathbf{h}_{i,k}]$$

模型训练：

划分训练/测试/验证集，拟合历史数据的特征和y的映射关系，选取在验证集上效果最好的模型。

六、部署方案

1. 仿真系统构建

核心理念：构建高保真度的离线仿真环境，支持多算法方案的安全对比实验，避免直接上线对业务大盘的冲击。

仿真系统架构：

- **历史数据回放引擎：**基于6个月完整历史数据构建订单流回放系统
- **资方状态模拟器：**模拟资方实时资金状态
- **多算法并行测试框架：**支持同时运行多个资配算法进行效果对比
- **仿真精度控制：**基本还原历史订单路由环境，精度>95%

仿真能力边界：

- ✓ 支持：算法逻辑验证、指标对比、参数调优
- ✗ 不支持：实时资方反馈、外部环境变化影响
- ⚡ 近似模拟：资方决策延迟、系统负载影响

仿真系统的验证指标：历史回放准确性 = 仿真结果与历史实际一致的订单数 / 历史总订单数

2. 算法评估指标（即业务关心的一系列优化目标）

仿真系统输出各项指标评估不同的算法效果：

$$\text{各算法效果评估指标} = \left\{ \begin{array}{l} \text{通过率} = \frac{\sum \text{订单通过数}}{\sum \text{订单总数}} \\ \text{资金利用率} = \frac{\text{实际放款金额}}{\text{资方总可用资金}} \\ \text{资产利用率} = \frac{\text{成功匹配资产数}}{\text{总可匹配资产数}} \\ \text{优质资产承接率} = \frac{\text{优质资产成功匹配数}}{\text{优质资产总数}} \\ \text{新客率} = \frac{\text{新客户成功匹配数}}{\text{总成功匹配数}} \\ \text{盈利金额} = \sum_{i=1}^n (\text{放款金额}_i \times \text{利率}_i) \\ \text{平均路由长度} = \frac{\sum_{i=1}^n \text{路由步数}_i}{n} \end{array} \right.$$

3. 加入对比的算法方案

对比方案：

- 方案一：现有规则引擎的贪心算法（基准）
- 方案二：现有的资配首推模型
- 方案三：聚类+KM算法
- 方案四：深度学习推荐算法

在仿真系统上有显著效果后可进行A/B实验上线验证。

4. A/B测试及全量推流

灰度策略：

- 第一阶段：5%流量（A组2.5% vs B组2.5%），观察2周
- 第二阶段：20%流量（A组10% vs B组10%），观察2周

关键指标：资金利用率、通过率、匹配成功率、响应时间、系统稳定性

5. 在灰度实验上有显著效果后可全量推流。